

Soluciones Tests 72–76: Probabilidad y Estadística

Mathematical AI Agent

August 18, 2026

Abstract

Demostraciones formales de resultados fundamentales en teoría de la probabilidad y estadística: la desigualdad de Cauchy–Schwarz para variables aleatorias, la desigualdad de Jensen para funciones convexas, la estabilidad de la distribución normal bajo suma y media, y la propiedad de insesgamiento del estimador de la media muestral.

1 Problemas

Theorem 1.1 (Desigualdad de Cauchy–Schwarz para variables aleatorias). *Sean X y Y variables aleatorias tal que $E[X^2] < \infty$ y $E[Y^2] < \infty$. Entonces*

$$(E[XY])^2 \leq E[X^2] E[Y^2].$$

Proof. Para cualquier $t \in \mathbb{R}$, consideramos la función cuadrática en t definida por

$$g(t) = E[(tX + Y)^2].$$

Dado que $(tX + Y)^2 \geq 0$ para todo t , se tiene $g(t) \geq 0$ para todo $t \in \mathbb{R}$. Desarrollando la expresión interior de la esperanza:

$$g(t) = E[t^2 X^2 + 2tXY + Y^2] = t^2 E[X^2] + 2t E[XY] + E[Y^2],$$

donde se ha utilizado la linealidad de la esperanza. Denotamos

$$a = E[X^2], \quad b = E[XY], \quad c = E[Y^2],$$

de modo que $g(t) = at^2 + 2bt + c$. Las hipótesis garantizan que $a \geq 0$ y $c \geq 0$ (son esperanzas de cuadrados).

Como $g(t) \geq 0$ para todo $t \in \mathbb{R}$ y $a \geq 0$, el polinomio cuadrático $at^2 + 2bt + c$ no puede tener dos raíces reales distintas (de lo contrario tomaría valores negativos entre ambas raíces). En el caso $a > 0$, el discriminante del polinomio debe satisfacer

$$\Delta = (2b)^2 - 4ac = 4b^2 - 4ac \leq 0,$$

lo que implica $b^2 \leq ac$, es decir,

$$(E[XY])^2 \leq E[X^2] E[Y^2].$$

Si $a = E[X^2] = 0$, entonces $X = 0$ casi seguro (pues $E[X^2] = 0 \Rightarrow X = 0$ c.s.), y la desigualdad se cumple trivialmente: $(E[0 \cdot Y])^2 = 0 \leq 0 \cdot E[Y^2] = 0$. $\square$

Theorem 1.2 (Desigualdad de Jensen para variables aleatorias). *Sea X una variable aleatoria tal que $E[|X|] < \infty$, y sea $f: \mathbb{R} \rightarrow \mathbb{R}$ una función convexa. Entonces*

$$f(E[X]) \leq E[f(X)],$$

siempre que ambas esperanzas estén definidas.

Proof. Sea $\mu = E[X]$. La convexidad de f implica que para todo $x \in \mathbb{R}$ existe un vector subgradiente $s_x \in \mathbb{R}$ tal que

$$f(x) \geq f(\mu) + s_x(x - \mu).$$

(En particular, si f es diferenciable en μ , podemos tomar $s_\mu = f'(\mu)$.)

Aplicando esta desigualdad al punto $X(\omega)$ para cada resultado elemental $\omega \in \Omega$:

$$f(X(\omega)) \geq f(\mu) + s_{X(\omega)}(X(\omega) - \mu).$$

Tomando esperanza en ambos lados:

$$E[f(X)] \geq f(\mu) + E[s_X(X - \mu)].$$

Para el caso más general, usamos la caracterización de la convexidad por rectas de soporte. Si f es convexa, entonces para todo $x_0 \in \mathbb{R}$ existe una constante m (que depende de x_0) tal que

$$f(x) \geq f(x_0) + m(x - x_0) \quad \text{para todo } x \in \mathbb{R}.$$

Tomando $x_0 = \mu = E[X]$ y aplicando al punto $X(\omega)$:

$$f(X(\omega)) \geq f(\mu) + m(X(\omega) - \mu).$$

Tomando esperanza:

$$E[f(X)] \geq f(\mu) + m E[X - \mu] = f(\mu) + m \cdot 0 = f(\mu).$$

Por lo tanto,

$$f(E[X]) \leq E[f(X)].$$

□

Theorem 1.3 (Suma de normales independientes). Sean $X \sim N(\mu_1, \sigma_1^2)$ y $Y \sim N(\mu_2, \sigma_2^2)$ variables aleatorias independientes. Entonces

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

Proof. Denotamos $Z = X + Y$. Calculamos la función característica de Z usando la independencia:

$$\varphi_Z(t) = E[e^{itZ}] = E[e^{it(X+Y)}] = E[e^{itX}] E[e^{itY}] = \varphi_X(t) \varphi_Y(t).$$

La función característica de una normal $N(\mu, \sigma^2)$ es

$$\varphi_X(t) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right).$$

Por tanto,

$$\begin{aligned} \varphi_Z(t) &= \exp\left(i\mu_1 t - \frac{1}{2}\sigma_1^2 t^2\right) \cdot \exp\left(i\mu_2 t - \frac{1}{2}\sigma_2^2 t^2\right) \\ &= \exp\left(i(\mu_1 + \mu_2)t - \frac{1}{2}(\sigma_1^2 + \sigma_2^2)t^2\right). \end{aligned}$$

Esta es exactamente la función característica de una distribución $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Como la función característica determina unívocamente la distribución (teorema de unicidad), concluimos que

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

□

Theorem 1.4 (Media de normales independientes). Sean $X_1, X_2, \dots, X_n$ variables aleatorias independientes tales que $X_i \sim N(\mu_i, \sigma_i^2)$ para $i = 1, \dots, n$. Entonces

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\frac{1}{n} \sum_{i=1}^n \mu_i, \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2\right).$$

En particular, si todas tienen la misma distribución $N(\mu, \sigma^2)$, entonces $\bar{X} \sim N(\mu, \sigma^2/n)$.

Proof. Procedemos por inducción sobre n . El caso base $n = 1$ es trivial: $\bar{X} = X_1 \sim N(\mu_1, \sigma_1^2)$.

Paso inductivo: Supongamos que el resultado es cierto para $n - 1$ variables normales independientes. Consideramos n variables $X_1, \dots, X_n$ con $X_i \sim N(\mu_i, \sigma_i^2)$.

Por la hipótesis inductiva, la media de las primeras $n - 1$ variables satisface

$$S_{n-1} = \frac{1}{n-1} \sum_{i=1}^{n-1} X_i \sim N\left(\frac{1}{n-1} \sum_{i=1}^{n-1} \mu_i, \frac{1}{(n-1)^2} \sum_{i=1}^{n-1} \sigma_i^2\right).$$

Sea $\mu' = \frac{1}{n-1} \sum_{i=1}^{n-1} \mu_i$ y $(\sigma')^2 = \frac{1}{(n-1)^2} \sum_{i=1}^{n-1} \sigma_i^2$, de modo que $S_{n-1} \sim N(\mu', (\sigma')^2)$.

La media de las n variables es

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \left((n-1)S_{n-1} + X_n \right) = \frac{n-1}{n} S_{n-1} + \frac{1}{n} X_n.$$

Aplicamos el Teorema 74 (suma de normales independientes) con las variables independientes $\frac{n-1}{n} S_{n-1}$ y $\frac{1}{n} X_n$. Tenemos:

- $\frac{n-1}{n} S_{n-1} \sim N\left(\frac{n-1}{n} \mu', \left(\frac{n-1}{n}\right)^2 (\sigma')^2\right),$
- $\frac{1}{n} X_n \sim N\left(\frac{1}{n} \mu_n, \frac{1}{n^2} \sigma_n^2\right).$

Por el Teorema 74, la suma es normal con:

$$\text{Media: } \frac{n-1}{n} \mu' + \frac{1}{n} \mu_n = \frac{1}{n} \sum_{i=1}^n \mu_i,$$

$$\text{Varianza: } \left(\frac{n-1}{n}\right)^2 (\sigma')^2 + \frac{1}{n^2} \sigma_n^2 = \frac{1}{n^2} \sum_{i=1}^{n-1} \sigma_i^2 + \frac{1}{n^2} \sigma_n^2 = \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2.$$

Esto completa la inducción. □

Theorem 1.5 (Insensamiento del estimador de la media muestral). Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria (variables independientes e idénticamente distribuidas) con $E[X_i] = \mu$ para todo i . Entonces el estimador de la media muestral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

es insesgado para μ , es decir, $E[\bar{X}] = \mu$.

Proof. Aplicamos la linealidad de la esperanza:

$$\begin{aligned} E[\bar{X}] &= E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] \\ &= \frac{1}{n} E\left[\sum_{i=1}^n X_i\right] \quad (\text{por linealidad de la esperanza}) \\ &= \frac{1}{n} \sum_{i=1}^n E[X_i] \quad (\text{por linealidad de la esperanza}) \\ &= \frac{1}{n} \sum_{i=1}^n \mu \quad (\text{por hipótesis: } E[X_i] = \mu \text{ para todo } i) \\ &= \frac{1}{n} \cdot n\mu \\ &= \mu. \end{aligned}$$

Por lo tanto, $E[\bar{X}] = \mu$, lo que demuestra que $\bar{X}$ es un estimador insesgado de μ .

Remark 1.6. El resultado anterior no requiere independencia ni distribución idéntica; basta con que $E[X_i] = \mu$ para cada i . La independencia y la identidad de distribución son necesarias para calcular la varianza de $\bar{X}$:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n},$$

donde $\sigma^2 = \text{Var}(X_i)$. Esta propiedad convierte a $\bar{X}$ en un estimador consistente (la varianza tiende a cero cuando $n \rightarrow \infty$).

□