

Soluciones Tests 82-85: Estadística

Mathematical AI Agent

August 18, 2026

1 Problemas

1.1 Test 82: Distribución chi-cuadrado de S^2

Theorem 1.1 (Distribución chi-cuadrado de la varianza muestral). *Sean $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución normal $\mathcal{N}(\mu, \sigma^2)$, con μ y σ^2 parámetros conocidos o desconocidos. La variable aleatoria*

$$T = \frac{(n-1)S^2}{\sigma^2}$$

sigue una distribución chi-cuadrado con $n-1$ grados de libertad, donde $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ es la varianza muestral.

Proof. Definimos las variables aleatorias estandarizadas:

$$Z_i = \frac{X_i - \mu}{\sigma}, \quad i = 1, 2, \dots, n.$$

Cada $Z_i \sim \mathcal{N}(0, 1)$ independientes entre sí. Sea $\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i = \frac{\bar{X} - \mu}{\sigma}$.

Consideramos la suma de cuadrados:

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2.$$

Descomponemos la suma de cuadrados total en la suma de cuadrados dentro y entre grupos. Definimos las variables:

$$W_i = Z_i - \bar{Z}, \quad i = 1, 2, \dots, n.$$

Observamos que $\sum_{i=1}^n W_i = \sum_{i=1}^n (Z_i - \bar{Z}) = n\bar{Z} - n\bar{Z} = 0$.

Entonces:

$$\begin{aligned} \sum_{i=1}^n Z_i^2 &= \sum_{i=1}^n (W_i + \bar{Z})^2 \\ &= \sum_{i=1}^n W_i^2 + 2\bar{Z} \sum_{i=1}^n W_i + n\bar{Z}^2 \\ &= \sum_{i=1}^n W_i^2 + n\bar{Z}^2. \end{aligned}$$

Ahora, notamos que:

$$\sum_{i=1}^n W_i^2 = \sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} - \frac{\bar{X} - \mu}{\sigma} \right)^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{(n-1)S^2}{\sigma^2}.$$

Por el lema de Cochran, sabemos que si $\sum_{i=1}^n Z_i^2 \sim \chi_n^2$, entonces $\sum_{i=1}^n W_i^2 \sim \chi_{n-1}^2$ y $n\bar{Z}^2 \sim \chi_1^2$ son independientes, y se cumple la descomposición:

$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n W_i^2 + n\bar{Z}^2.$$

Para demostrar la independencia, notamos que las variables W_i son combinaciones lineales de las Z_i con la restricción $\sum W_i = 0$. Por la propiedad de la distribución normal multivariante, como $\bar{Z}$ es una función lineal de las Z_i y $\sum W_i = 0$, y dado que la distribución conjunta de las Z_i es simétrica bajo rotaciones en el subespacio ortogonal a $(1, 1, \dots, 1)$, concluimos que $\sum W_i^2$ es independiente de $\bar{Z}$.

Finalmente, como $\sum_{i=1}^n Z_i^2 \sim \chi_n^2$ y $\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n W_i^2 + n\bar{Z}^2$ con $\sum_{i=1}^n W_i^2$ independiente de $n\bar{Z}^2 \sim \chi_1^2$, por la aditividad de los grados de libertad de distribuciones chi-cuadrado independientes, se sigue que:

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n W_i^2 \sim \chi_{n-1}^2.$$

□

1.2 Test 83: EMV de p en Bernoulli

Theorem 1.2 (Estimador de máxima verosimilitud para la distribución Bernoulli). *Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución Bernoulli con parámetro $p \in (0, 1)$. El estimador de máxima verosimilitud de p es $\hat{p} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.*

Proof. La función de masa de probabilidad de una distribución Bernoulli es:

$$P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}.$$

Para una muestra aleatoria $X_1, X_2, \dots, X_n$ independientes e idénticamente distribuidas, la función de verosimilitud es:

$$\begin{aligned} L(p; x_1, \dots, x_n) &= \prod_{i=1}^n P(X_i = x_i) \\ &= \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}. \end{aligned}$$

Definimos $S = \sum_{i=1}^n X_i$ como el número de éxitos en la muestra. Entonces la función de verosimilitud se escribe como:

$$L(p) = p^S (1-p)^{n-S}.$$

Para facilitar la maximización, tomamos el logaritmo de la verosimilitud (log-verosimilitud):

$$\ell(p) = \log L(p) = S \log p + (n - S) \log(1 - p).$$

Derivamos respecto a p e igualamos a cero:

$$\frac{d\ell}{dp} = \frac{S}{p} - \frac{n-S}{1-p} = 0.$$

Resolviendo para p :

$$\begin{aligned}\frac{S}{p} &= \frac{n-S}{1-p} \\ S(1-p) &= (n-S)p \\ S - Sp &= np - Sp \\ S &= np \\ \hat{p} = \frac{S}{n} &= \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.\end{aligned}$$

Verificamos que es un máximo calculando la segunda derivada:

$$\frac{d^2\ell}{dp^2} = -\frac{S}{p^2} - \frac{n-S}{(1-p)^2} < 0, \quad \text{para } p \in (0, 1),$$

ya que $S \geq 0$ y $n-S \geq 0$, con $S > 0$ o $n-S > 0$ (para $0 < p < 1$ con probabilidad 1). Por tanto, $\hat{p} = \bar{X}$ es un punto de máximo de la función de verosimilitud.

Además, como la función de verosimilitud es continua en $p \in (0, 1)$ y $\hat{p} = \bar{X} \in [0, 1]$, si $\bar{X} = 0$ o $\bar{X} = 1$, el máximo se alcanza en el borde del dominio. Para $0 < \bar{X} < 1$, el EMV es $\hat{p} = \bar{X}$, que es un estimador insesgado y consistente de p . $\square$

1.3 Test 84: Información de Fisher en Bernoulli

Theorem 1.3 (Información de Fisher para distribución Bernoulli). *Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria de una distribución Bernoulli con parámetro $p \in (0, 1)$. La información de Fisher para las n observaciones es:*

$$I(p) = \frac{n}{p(1-p)}.$$

Proof. La función de masa de probabilidad de una distribución Bernoulli es:

$$f(x; p) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}.$$

Para una sola observación, el logaritmo de la función de verosimilitud es:

$$\ell(p; x) = \log f(x; p) = x \log p + (1-x) \log(1-p).$$

Calculamos la primera derivada (escoración o *score*):

$$\frac{d\ell}{dp} = \frac{x}{p} - \frac{1-x}{1-p}.$$

La información de Fisher para una observación es:

$$I_1(p) = -\mathbb{E} \left[\frac{d^2\ell}{dp^2} \right].$$

Calculamos la segunda derivada:

$$\frac{d^2\ell}{dp^2} = -\frac{x}{p^2} - \frac{1-x}{(1-p)^2}.$$

Tomamos la esperanza:

$$\begin{aligned}
\mathbb{E} \left[\frac{d^2 \ell}{dp^2} \right] &= \mathbb{E} \left[-\frac{X}{p^2} - \frac{1-X}{(1-p)^2} \right] \\
&= -\frac{\mathbb{E}[X]}{p^2} - \frac{1-\mathbb{E}[X]}{(1-p)^2} \\
&= -\frac{p}{p^2} - \frac{1-p}{(1-p)^2} \quad (\text{ya que } \mathbb{E}[X] = p) \\
&= -\frac{1}{p} - \frac{1}{1-p} \\
&= -\frac{(1-p) + p}{p(1-p)} \\
&= -\frac{1}{p(1-p)}.
\end{aligned}$$

Por tanto, la información de Fisher para una observación es:

$$I_1(p) = -\mathbb{E} \left[\frac{d^2 \ell}{dp^2} \right] = \frac{1}{p(1-p)}.$$

Para n observaciones independientes e idénticamente distribuidas, la información de Fisher es aditiva:

$$I(p) = n \cdot I_1(p) = \frac{n}{p(1-p)}.$$

Esto se demuestra directamente: para n observaciones, la log-verosimilitud conjunta es $\ell_n(p) = \sum_{i=1}^n \ell(p; x_i)$, y la segunda derivada es $\frac{d^2 \ell_n}{dp^2} = \sum_{i=1}^n \frac{d^2 \ell(p; x_i)}{dp^2}$. Por linealidad de la esperanza:

$$I(p) = -\mathbb{E} \left[\frac{d^2 \ell_n}{dp^2} \right] = \sum_{i=1}^n \left(-\mathbb{E} \left[\frac{d^2 \ell(p; X_i)}{dp^2} \right] \right) = n \cdot \frac{1}{p(1-p)} = \frac{n}{p(1-p)}.$$

□

1.4 Test 85: Desigualdad de Cramér-Rao

Theorem 1.4 (Desigualdad de Cramér-Rao). *Sea $\mathbf{X} = (X_1, \dots, X_n)$ una variable aleatoria con función de densidad (o masa) $f(\mathbf{x}; \theta)$ que depende de un parámetro $\theta \in \Theta \subseteq \mathbb{R}$. Supongamos que:*

1. *El soporte de f no depende de θ .*
2. *Las derivadas parciales de primer y segundo orden de f respecto a θ existen y son integrables (o sumables) para todo θ .*
3. *La información de Fisher $I(\theta) = \mathbb{E} \left[\left(\frac{\partial \log f}{\partial \theta} \right)^2 \right] > 0$ existe y es finita.*

Entonces, para cualquier estimador insesgado $\hat{\theta}$ de θ , se cumple:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{I(\theta)} = \frac{1}{\mathbb{E} \left[\left(\frac{\partial \log f}{\partial \theta} \right)^2 \right]}.$$

Proof. Definimos la *eskorada* (score function) como:

$$U(\theta) = \frac{\partial \log f(\mathbf{X}; \theta)}{\partial \theta}.$$

Paso 1: Propiedades de la eskorada. Demostramos que $\mathbb{E}[U(\theta)] = 0$ para todo θ . La función de densidad satisface:

$$\int f(\mathbf{x}; \theta) d\mathbf{x} = 1 \quad (\text{o } \sum_{\mathbf{x}} f(\mathbf{x}; \theta) = 1 \text{ para el caso discreto}).$$

Derivando ambos lados respecto a θ :

$$\frac{\partial}{\partial \theta} \int f(\mathbf{x}; \theta) d\mathbf{x} = \int \frac{\partial f(\mathbf{x}; \theta)}{\partial \theta} d\mathbf{x} = 0.$$

Por la regla de la cadena:

$$\frac{\partial f}{\partial \theta} = f(\mathbf{x}; \theta) \cdot \frac{\partial \log f(\mathbf{x}; \theta)}{\partial \theta} = f(\mathbf{x}; \theta) \cdot U(\theta).$$

Por tanto:

$$\int U(\theta) f(\mathbf{x}; \theta) d\mathbf{x} = \int \frac{\partial f(\mathbf{x}; \theta)}{\partial \theta} d\mathbf{x} = 0,$$

lo que implica $\mathbb{E}[U(\theta)] = 0$.

Paso 2: Covarianza entre $U(\theta)$ y $\hat{\theta}$. Sea $\hat{\theta} = g(\mathbf{X})$ un estimador insesgado de θ , es decir, $\mathbb{E}[\hat{\theta}] = \theta$ para todo θ . Entonces:

$$\frac{\partial}{\partial \theta} \mathbb{E}[\hat{\theta}] = \frac{\partial \theta}{\partial \theta} = 1.$$

Por otro lado:

$$\begin{aligned} \frac{\partial}{\partial \theta} \mathbb{E}[\hat{\theta}] &= \frac{\partial}{\partial \theta} \int \hat{\mathbf{x}}(\mathbf{x}) f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \int \hat{\mathbf{x}}(\mathbf{x}) \frac{\partial f(\mathbf{x}; \theta)}{\partial \theta} d\mathbf{x} \\ &= \int \hat{\mathbf{x}}(\mathbf{x}) U(\theta) f(\mathbf{x}; \theta) d\mathbf{x} \\ &= \mathbb{E}[\hat{\theta} \cdot U(\theta)]. \end{aligned}$$

Por tanto, $\mathbb{E}[\hat{\theta} \cdot U(\theta)] = 1$.

Calculamos la covarianza entre $\hat{\theta}$ y $U(\theta)$:

$$\begin{aligned} \text{Cov}(\hat{\theta}, U(\theta)) &= \mathbb{E}[\hat{\theta} \cdot U(\theta)] - \mathbb{E}[\hat{\theta}] \cdot \mathbb{E}[U(\theta)] \\ &= 1 - \theta \cdot 0 = 1. \end{aligned}$$

Paso 3: Aplicación de la desigualdad de Cauchy-Schwarz. Por la desigualdad de Cauchy-Schwarz:

$$[\text{Cov}(\hat{\theta}, U(\theta))]^2 \leq \text{Var}(\hat{\theta}) \cdot \text{Var}(U(\theta)).$$

Calculamos $\text{Var}(U(\theta))$:

$$\begin{aligned} \text{Var}(U(\theta)) &= \mathbb{E}[U(\theta)^2] - (\mathbb{E}[U(\theta)])^2 \\ &= \mathbb{E} \left[\left(\frac{\partial \log f}{\partial \theta} \right)^2 \right] - 0^2 \\ &= I(\theta). \end{aligned}$$

Sustituyendo en la desigualdad de Cauchy-Schwarz:

$$1^2 \leq \text{Var}(\hat{\theta}) \cdot I(\theta).$$

Despejando:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{I(\theta)}.$$

Esto completa la demostración de la desigualdad de Cramér-Rao. El límite inferior $\frac{1}{I(\theta)}$ se conoce como el **límite inferior de Cramér-Rao** (CRLB). Un estimador que alcanza este límite se dice que es **eficiente**. $\square$